



FINTRACKER

Memoria Final del Proyecto

Mateo Pérez Suarez (79439806Z)
Iñigo Peña de las Heras (20983346D)

Github Repository

14 de enero de 2026

Índice

1. Propuesta de Proyecto	3
1.1. Motivación y objetivo	3
1.2. Descripción del problema	3
1.3. Related Work	5
1.3.1. Financial Event Extraction Using Wikipedia-Based Weak Supervision (Ein-Dor et al., 2019)	5
1.3.2. Extracting Fine-Grained Economic Events from Business News (Jacobs et al., 2020)	5
1.3.3. A Review of Sentiment, Semantic and Event-Extraction-Based Approaches in Stock Forecasting	5
1.3.4. SEntFiN 1.0: Entity-Aware Sentiment Analysis for Financial News	6
1.3.5. LLM-based Extraction and Summarization for Financial News	6
1.4. Aprendizajes de la propuesta	7
2. Extracción y procesamiento inicial de los Datos	8
2.1. Generación de etiquetas mediante modelado no supervisado	9
2.2. Análisis Exploratorio del corpus	10
3. Procesamiento y Análisis de los Datos	11
3.1. Preprocesamiento para métodos no contextuales	12
3.1.1. Implementación del preprocesamiento	12
3.1.2. Análisis de resultados	13
3.2. Preprocesamiento para modelos contextuales	14
3.2.1. Tokenización para BERT	15
3.2.2. Tokenización para FinBERT	15
4. Generación de Embeddings	16
4.1. Métodos de representación tradicionales	16
4.1.1. Análisis comparativo de resultados	16
4.2. Embeddings no contextuales	18
4.2.1. Modelos implementados	18
4.2.2. Cobertura y calidad de los embeddings	18
4.2.3. Análisis semántico y visualización	19
4.2.4. Conclusiones y modelo más adecuado	20
4.3. Embeddings contextuales	20
4.3.1. Embeddings BERT	21
4.3.2. Embeddings FinBERT	21

4.4. Lecciones aprendidas	21
5. Primera Iteración del Modelo	22
5.1. Modelos y enfoques utilizados	22
5.1.1. Shallow Learning	22
5.1.2. Deep Learning	22
5.2. Primeros resultados obtenidos	23
5.2.1. Clasificación de texto	23
5.2.2. Generación de resúmenes	24
5.3. Lecciones aprendidas	25
6. Segunda iteración	26
6.1. Text Summarization	26
6.1.1. Implementación y Procesamiento	26
6.1.2. Evaluación y Comparativa con Iteraciones Previas	26
6.1.3. T5 vs. Inferencia Local con LLM (Ollama)	27
6.2. Clasificación de Textos	28
6.2.1. Entrenamiento y fine-tuning	29
6.2.2. Comparativa de resultados de los Modelos de Transformers	31
6.2.3. Comparativa Respecto a los métodos de Shallow y Deep learning	33
6.3. Extracción de Entidades	35
6.3.1. Arquitectura y Modelo: Neuro-BERT	35
6.3.2. Proceso de Implementación	35
6.3.3. Evaluación Cualitativa y Análisis de Errores	36
6.4. Comparativa de resultados finales	37
6.5. Lecciones aprendidas	37
7. Muestra de ejecución del proyecto	37
8. Conclusiones	38
8.1. Conclusiones generales	38
8.2. Limitaciones del proyecto	39
8.3. Trabajo futuro	40

1 Propuesta de Proyecto

1.1 Motivación y objetivo

Las redes neuronales para language modeling están siendo probadas como resoluciones efectivas a subtarefas del procesamiento de lenguaje natural (NLP), especialmente en dominios más concretos y que requieren de cierta especialización donde la densidad informativa puede llegar a ser crítica. En el ámbito financiero, la cantidad de datos proveniente tanto de noticias como de informes y comunicados de las distintas empresas supone un reto constante para analistas financieros. La necesidad de procesar estos grandes volúmenes de información en tiempo real para identificar hechos con impacto potencial en los mercados requiere del desarrollo de herramientas automatizadas que ayuden a optimizar el objetivo final, ser capaces de tomar decisiones estratégicas en base a estos datos.

El objetivo principal de este proyecto, al que hemos llamado FinTracker, es el desarrollo de un sistema para la detección automática de eventos financieros considerados relevantes. El sistema se centra en identificar y estructurar distintos tipos de eventos considerados de alto impacto, como por ejemplo podrían ser: fusiones y adquisiciones, cambios de directiva y anuncios de resultados financieros. Para ello, el pipeline propuesto combina distintas tareas del ámbito del NLP como serían la clasificación de documentos, el reconocimiento de entidades (NER) y la generación de resúmenes abstractivos, con el fin de transformar el contenido extenso que contienen las noticias en una representación estructurada y una visión condensada de la información.

1.2 Descripción del problema

El desafío central de este proyecto reside en la naturaleza no estructurada y la cantidad abusiva de volumen de información financiera disponible en la web, donde gran parte de los datos provienen de fuentes cuya fiabilidad no siempre es comprobable. Si bien existen plataformas de referencia global como Bloomberg, su acceso restringido mediante licencias comerciales dificulta la extracción lícita de datos para fines de investigación académica.

Como alternativa, se ha optado por el uso de la API de Finnhub[9], que permite acceder a un flujo tanto en tiempo real como histórico de noticias de las compañías tecnológicas líderes (Apple, Amazon, Google, Meta, Microsoft, Nvidia y Tesla), así como de mercados de criptoactivos los cuales no serán gestionados en este proyecto. Sin embargo, los datos en bruto presentan obstáculos significativos para su análisis directo: las URLs proporcionadas suelen ser redireccionamientos que no apuntan al artículo final y el texto extraído mediante técnicas de scraping suele contener abundante ruido. estructural, como avisos de cookies, errores de carga o textos promocionales. Estos retos técnicos fueron identificados en esta fase inicial y quedaron explícitamente planteados para ser abordados y resueltos en las fases posteriores de procesamiento de los datos.

A nivel técnico, la resolución del problema se ha dividido en tres subtarefas principales:

- **Clasificación de eventos:** El sistema debe ser capaz de categorizar automáticamente las noticias según el tipo de suceso o texto financiero que representan, identificando los eventos de las categorías que se presentarán más adelante.
- **Reconocimiento de Entidades Nombradas (NER):** El objetivo en esta fase es extraer de forma más precisa posible los actores principales de cada noticia, tales como los nombres de las empresas implicadas, directivos mencionados y cifras económicas clave (fechas, porcentajes o valores monetarios), garantizando que el sistema identifique correctamente el contexto de la información.
- **Generación de resúmenes:** Finalmente, se busca optimizar la presentación del contenido mediante la creación de resúmenes breves y concisos. Esta tarea tiene como fin sintetizar el contenido de la publicación para que sea consumible de forma rápida sin perder la precisión informativa.

En resumen, la tarea que se pretende resolver es tanto la creación de un sistema capaz de resumir, clasificar y sintetizar noticias financieras, transformándola en una herramienta de análisis fácil de entender e interpretable para el usuario objetivo.




Figura 1: Representación de una visión conceptual inicial de la generación de tickers, que fue refinada y ajustada en entregas posteriores.

1.3 Related Work

1.3.1. Financial Event Extraction Using Wikipedia-Based Weak Supervision (Ein-Dor et al., 2019)

El trabajo de Ein-Dor et al. [8] aborda el problema de la detección de eventos financieros desde una perspectiva de **supervisión débil**, con el objetivo de reducir la dependencia de grandes corpus anotados manualmente. Para ello, los autores explotan secciones de Wikipedia asociadas a miles de compañías como fuente indirecta de supervisión y entrenan clasificadores basados en **BERT**. Los experimentos muestran resultados muy competitivos, alcanzando un **F1 de 0,94** en evaluaciones internas y manteniendo un *recall* superior al 70 % cuando se aplican a noticias reales, superando a enfoques tradicionales. No obstante, el estudio también pone de manifiesto una caída de rendimiento al transferir el modelo de Wikipedia a noticias, atribuida principalmente a diferencias de estilo y a una cobertura limitada de ciertos tipos de eventos.

1.3.2. Extracting Fine-Grained Economic Events from Business News (Jacobs et al., 2020)

Con el objetivo de avanzar hacia una extracción más granular de eventos económicos, Jacobs et al. [11] introducen el corpus **SentiVent**, anotado manualmente con distintos tipos de eventos financieros y sus argumentos. A partir de este recurso, los autores evalúan modelos de clasificación y etiquetado de secuencia, incluyendo arquitecturas **BiLSTM-CRF** y variantes con embeddings contextuales como **BERT**, en tareas de detección de *triggers* y extracción de argumentos. Los resultados obtenidos sitúan el **F1 entre el 60 y el 70 %** para la detección de triggers, mientras que la extracción de argumentos presenta un rendimiento sensiblemente inferior, reflejando la complejidad de capturar relaciones semánticas finas en textos financieros. Este trabajo destaca tanto por la aportación de un corpus de referencia como por evidenciar la necesidad de modelos capaces de manejar dependencias largas y contexto a nivel de documento.

1.3.3. A Review of Sentiment, Semantic and Event-Extraction-Based Approaches in Stock Forecasting

Desde una perspectiva más global, Cheng et al. [5] realizan una revisión exhaustiva de los enfoques de predicción financiera basados en análisis de sentimiento, semántica y extracción de eventos, proponiendo una taxonomía comparativa de técnicas y fuentes textuales. Uno de los principales hallazgos del estudio es que los métodos **híbridos**, que combinan estas tres dimensiones, tienden a ofrecer mejores resultados que los enfoques aislados. Asimismo, la revisión identifica retos persistentes en el área, como la heterogeneidad de los datos, la ausencia de métricas de evaluación estandarizadas y la dificultad

de desplegar estos sistemas en entornos de tiempo real. En conjunto, el trabajo proporciona una visión consolidada del estado del arte y señala líneas futuras de investigación, entre ellas la creación de datasets más amplios y la integración de múltiples fuentes de información.

1.3.4. SEntFiN 1.0: Entity-Aware Sentiment Analysis for Financial News

El estudio de Sinha et al. [20] se centra en el análisis de sentimiento financiero a nivel de entidad, superando las limitaciones de los enfoques globales que asignan una única etiqueta por documento. Como principal contribución, los autores presentan el corpus **SEntFiN 1.0**, compuesto por más de 10.700 titulares y 14.400 anotaciones entidad-sentimiento, constituyendo el primer dataset a gran escala de este tipo en el dominio financiero. Los experimentos muestran que modelos contextuales como **RoBERTa** y **FinBERT** alcanzan hasta un **94 % de exactitud**, superando ampliamente a enfoques léxicos y tradicionales. El trabajo pone de relieve la importancia de incorporar conciencia de entidad para captar impactos diferenciados dentro de una misma noticia, aunque señala como limitación el hecho de que el corpus se restrinja a titulares en inglés.

1.3.5. LLM-based Extraction and Summarization for Financial News

Más recientemente, Dolphin et al. [7] exploran el uso de **LLMs** en un pipeline de extracción estructurada que combina detección de entidades, análisis de sentimiento y generación automática de resúmenes. A partir de un conjunto de 5.500 artículos financieros, los autores muestran que en aproximadamente el **90 %** de los casos los tickers detectados coinciden con los de feeds comerciales, y que en un **22 %** de los artículos se identifican entidades adicionales no presentes en dichas fuentes. Los resúmenes generados resultan más informativos y específicos que los obtenidos mediante métodos extractivos simples. El estudio demuestra la viabilidad práctica de integrar LLMs en el análisis financiero, al tiempo que señala desafíos relevantes relacionados con el coste computacional y el diseño de *prompts*.

Cuadro 1: Resumen de trabajos relevantes en extracción de eventos y análisis financiero

Paper	Principales aportaciones / Resultados
<i>Financial Event Extraction Using Wikipedia-Based Weak Supervision</i> (Ein-Dor et al., 2019)	Uso de supervisión débil con Wikipedia para generar datos de entrenamiento. Modelos basados en BERT alcanzan F1 = 0.94 en Extended-wiki y recall = 0.77 en noticias reales, superando a enfoques supervisados tradicionales.
<i>Extracting Fine-Grained Economic Events from Business News</i> (Jacobs et al., 2020)	Creación del corpus SENTiVENT. Evaluación con BiLSTM-CRF y BERT: detección de triggers con F1 del 60–70 %, pero extracción de argumentos con rendimiento sensiblemente inferior.
<i>Extracting Structured Insights from Financial News: An Augmented LLM Driven Approach</i> (Dolphin et al., 2024)	Pipeline con LLMs para extracción de entidades, sentimiento y resúmenes. Cobertura del 90 % de tickers respecto a feeds comerciales y descubrimiento de un 22 % de entidades adicionales.
<i>SEntFiN 1.0: Entity-Aware Sentiment Analysis for Financial News</i> (Sinha et al., 2023)	Dataset con 10.700 titulares y 14.400 anotaciones entidad-sentimiento. Modelos FinBERT y RoBERTa alcanzan hasta un 94 % de exactitud y 93 % de F1.
<i>A Review of Sentiment, Semantic and Event-Extraction-Based Financial Forecasting Approaches</i> (Cheng et al., 2022)	Revisión de enfoques basados en sentimiento, semántica y extracción de eventos. Se concluye que los métodos híbridos ofrecen mejores resultados, aunque persisten problemas de generalización.

1.4 Aprendizajes de la propuesta

Esta propuesta se tomó como punto de partida para definir la hoja de ruta general del proyecto y facilitar el establecer los objetivos y subtarefas principales de nuestro proyecto, FinTracker. En particular, ayudó a sentar las bases tanto para el diseño del pipeline de extracción y preprocesamiento de los datos desarrollado a continuación en el procesamiento y análisis de los datos, como para la posterior evaluación comparativa de modelos tanto clásicos como neuronales abordada en secciones posteriores.

Si bien esta entrega no se tomó como una solución final, permitió evidenciar que, aunque el planteamiento inicial resultaba adecuado para acotar el problema y definir un marco de trabajo razonable, algunas de las tareas propuestas eran todavía ambiguas

o excesivamente amplias. Como consecuencia, a lo largo del desarrollo del proyecto se introdujeron pequeños cambios estructurales en la definición de las tareas, con el objetivo de afinar el alcance del sistema y adaptar las decisiones técnicas a las limitaciones reales de los datos y de los recursos disponibles.

En este sentido, la propuesta inicial cumplió una función fundamental de exploración inicial, proporcionando una base sólida de comprensión del estado del arte y de las posibilidades reales del proyecto. Esto nos permitió identificar de forma temprana los principales retos que podríamos enfrentar en el ámbito financiero y ajustar progresivamente el enfoque hacia soluciones más realistas.

2 Extracción y procesamiento inicial de los Datos

Tal y como se expuso en la propuesta inicial del proyecto, el dominio financiero presenta una combinación de alto volumen informativo y una estructura textual heterogénea, procedente principalmente de noticias, comunicados corporativos y artículos especializados. Esta naturaleza no estructurada, junto con la necesidad de identificar eventos relevantes de forma automatizada, motivó la construcción de un corpus de noticias financieras como punto de partida del proyecto.

Siguiendo este planteamiento, se recopiló un conjunto de noticias mediante la API de Finnhub [9], añadiendo a la lista de las compañías contempladas en un inicio (Apple, Amazon, Google, Meta, entre otras) empresas consideradas de menor tamaño con el objetivo de introducir mayor diversidad léxica y temática y evaluar la capacidad de generalización de los modelos desarrollados posteriormente.

En cuanto a los problemas anticipados en la descripción inicial del problema, los datos obtenidos en bruto presentaban limitaciones significativas para su análisis directo. En particular, las URLs proporcionadas por la API suelen corresponder a redirecciones que no apuntan al contenido final del artículo, y los textos extraídos mediante técnicas de scraping contienen con frecuencia ruido estructural, como avisos de cookies, errores de carga o fragmentos promocionales.

En esta fase del proyecto, dichos retos fueron abordados mediante un proceso de preparación del corpus orientado a resolver las redirecciones de URLs, extraer únicamente el contenido textual principal de cada noticia y descartar documentos inválidos o carentes de información semántica relevante mediante distintos filtros de longitud o de frases recurrentes en los artículos fallidos. Como resultado, se obtuvo un conjunto de documentos mejor estructurado, adecuado para las etapas posteriores de análisis exploratorio, preprocesamiento lingüístico y generación de representaciones del lenguaje mediante embeddings.

2.1 Generación de etiquetas mediante modelado no supervisado

En la propuesta inicial del proyecto se planteó como tarea principal la detección de eventos financieros de alto impacto, tales como fusiones y adquisiciones, cambios en la directiva de las compañías y anuncios de resultados financieros. No obstante, el corpus de noticias recopilado carecía de anotaciones previas que permitieran identificar de forma directa este tipo de eventos, lo que hizo necesario definir una estrategia alternativa para estructurar los datos de partida.

Con este objetivo, se adoptó un enfoque de modelado no supervisado basado en técnicas de topic-modeling, que permite identificar patrones semánticos latentes a partir de la distribución de términos en el corpus sin requerir datos anotados manualmente. En particular, los documentos fueron representados mediante una matriz Bag-of-Words y se aplicó un modelo de Non-negative Matrix Factorization (NMF) [19] para descomponer el espacio léxico en un conjunto reducido de componentes interpretables.

Durante este análisis inicial se observó que las categorías de eventos definidas inicialmente no se reflejaban de forma clara ni homogénea en la estructura semántica del corpus obtenido. En lugar de agruparse estrictamente en torno a eventos concretos como fusiones o cambios de directiva, las noticias tendían a organizarse según temáticas más amplias relacionadas con el contexto económico, tecnológico y de mercado en el que dichos eventos se enmarcan.

Por este motivo, el número de tópicos se fijó en cinco, con la intención de mejorar la interpretabilidad, y tras un análisis de la coherencia de los términos más representativos de cada componente. A partir de estos resultados, cada tópico fue interpretado manualmente y asociado a una categoría temática que reflejaba el contenido predominante de los documentos agrupados. Las categorías resultantes corresponden a:

Cuadro 2: Categorías temáticas obtenidas mediante modelado no supervisado

Categoría	Descripción semántica
<i>Business Growth and Cloud Infrastructure in the AI Industry</i>	Agrupar noticias relacionadas con empresas tecnológicas, inteligencia artificial, crecimiento empresarial e infraestructuras cloud, reflejando la expansión del sector tecnológico.
<i>Financial and Market News and Corporate Sales</i>	Incluye textos centrados en resultados financieros, cotizaciones bursátiles, ventas corporativas y actividad económica de grandes compañías.
<i>Stock Market and Trading</i>	Contiene términos asociados a trading, inversión, ETFs y criptomonedas, describiendo la actividad de los mercados financieros.
<i>Quantum Computing and Military Technology</i>	Reúne vocabulario técnico vinculado a computación cuántica, industria y defensa, representando un tema centrado en innovación tecnológica y aplicaciones militares.
<i>Informal / Conversational Language</i>	Agrupar textos con lenguaje informal o conversacional, como citas o expresiones no temáticas, sin coherencia semántica relevante.

Este proceso permitió transformar un corpus inicialmente no etiquetado en un conjunto de documentos con etiquetas aproximadas, que si bien no seguían la etiquetación propuesta en un inicio, sirvieron como estructura para el proyecto.

2.2 Análisis Exploratorio del corpus

Con el objetivo de comprender mejor la estructura y características del corpus obtenido tras las fases iniciales de recopilación y etiquetación, se realizó un análisis exploratorio de los datos. Este análisis permitió identificar patrones generales, posibles desequilibrios entre categorías y propiedades básicas del texto que resultan relevantes para las etapas posteriores del pipeline.

De este modo se analizó la distribución de las noticias según las categorías temáticas obtenidas mediante el modelado no supervisado. Como se muestra en la Figura 2, la distribución no es uniforme, observándose una mayor concentración de documentos en categorías relacionadas con noticias financieras y de mercado, así como con actividad bursátil, frente a tópicos más específicos como Quantum computing y Military Technology. Este desbalance refleja la naturaleza del flujo informativo financiero y será tenido en cuenta en las tareas posteriores, especialmente en la clasificación.

A pesar de esto y como resultado de las fases de obtención, preparación y análisis ex-




Figura 2: Distribución de documentos por categoría temática obtenida mediante modelo no supervisado.

ploratorio, se dispone de un dataset estructurado que constituye la base para las siguientes etapas del proyecto. Cada instancia del corpus incluye la siguiente información:

- **headline:** titular original de la noticia.
- **summary:** resumen proporcionado por la fuente.
- **article_text:** texto principal del artículo tras el proceso de limpieza y extracción.
- **company:** empresa o entidad principal asociada a la noticia.
- **topic:** etiqueta temática aproximada asignada mediante modelado no supervisado.

3 Procesamiento y Análisis de los Datos

Una vez definido el corpus inicial y generada una primera estructura temática mediante modelado no supervisado, se procedió al preprocesamiento de los textos con el objetivo de adecuarlos a las distintas estrategias de representación del lenguaje empleadas en el proyecto. Dado que las técnicas consideradas abarcan desde métodos tradicionales y no contextuales hasta modelos contextuales basados en arquitecturas Transformer, fue necesario diseñar procesos de preprocesado diferenciados y adaptados a las particularidades de cada enfoque.

En este sentido, el preprocesamiento no se abordó como una etapa única y uniforme, sino como un conjunto de transformaciones específicas en función del tipo de representación a generar. Para los métodos tradicionales y embeddings no contextuales se aplicaron técnicas orientadas a la normalización léxica y la reducción del ruido estadístico, mientras que para los modelos contextuales se preservó en mayor medida la estructura original del texto con el fin de mantener la información contextual necesaria para su correcta interpretación. A continuación, se describen en detalle los distintos procesos aplicados en cada caso.

3.1 Preprocesamiento para métodos no contextuales

Para las representaciones no contextuales se optó por utilizar la librería spaCy [10] en lugar de NLTK para las tareas de tokenización y normalización léxica. Esta decisión se fundamenta en el uso del modelo de lenguaje preentrenado *en_core_web_sm*, que permite agrupar de forma eficiente múltiples tareas lingüísticas en un único pipeline optimizado, incluyendo tokenización, POS-tagging y lematización cuando resulta necesario. Al cargar el modelo de spaCy, se desactivaron explícitamente los componentes de *parser*, *textcat* y *NER*, ya que no son requeridos para las tareas de preprocesamiento consideradas y podrían introducir modificaciones innecesarias en los tokens normalizados.

Dado que los métodos no contextuales considerados en el proyecto presentan requisitos distintos, se diseñaron dos pipelines de preprocesamiento diferenciados. Por un lado, se construyó un pipeline con lematización destinado exclusivamente a los métodos tradicionales basados en frecuencias (*Bag-of-Words (BoW)* y *TF-IDF*), donde la reducción morfológica contribuye a disminuir la dimensionalidad del vocabulario y a mejorar la interpretabilidad de las representaciones. Por otro lado, se definió un pipeline sin lematización para los embeddings no contextuales, preservando las formas superficiales de las palabras, ya que estos modelos capturan relaciones semánticas a partir de co-ocurrencias léxicas y una normalización excesiva puede degradar la calidad de las representaciones aprendidas.

3.1.1. Implementación del preprocesamiento

El preprocesamiento se implementó mediante un pipeline de dos fases con el objetivo de separar claramente la limpieza inicial del texto de las transformaciones lingüísticas posteriores. La primera fase se centró en la limpieza y normalización básica del texto mediante la aplicación de un conjunto de reglas diseñadas para eliminar ruido estructural. En esta etapa se eliminaron elementos como URLs, etiquetas HTML y fragmentos *boilerplate* (por ejemplo, textos del tipo *read more* o avisos de copyright) derivados del proceso de scraping. Asimismo, se normalizó la puntuación tipográfica y se eliminaron caracteres residuales. Adicionalmente, se aplicó *case folding*, convirtiendo todo el texto a minúsculas con el fin de unificar tokens y evitar distinciones artificiales debidas a mayúsculas al inicio de frase.

Un componente clave de esta fase fue la introducción de *placeholders* semánticos. Durante el análisis exploratorio del corpus se identificó que la presencia abundante de cifras numéricas, porcentajes y cantidades monetarias con valores altamente variables incrementaba significativamente la *sparsity* del vocabulario. Para mitigar este efecto, se sustituyeron dichas entidades por tokens genéricos que representan su categoría semántica, como se ilustra a continuación:

- 10.5% o 20 per cent → __PERCENT__

- \$10 million o €20bn → `__MONEY__`
- 2024, 1998 → `__YEAR__`
- \$TSLA → `__TICKER__`

En la segunda fase se aplicaron transformaciones específicas en función del pipeline considerado. Para el pipeline lematizado, destinado a los métodos tradicionales, se utilizó el pipeline de spaCy para obtener la forma canónica de las palabras y se eliminaron las *stopwords* estándar, reduciendo así el ruido estadístico y la dimensionalidad del vocabulario. Para el pipeline no lematizado, empleado en los embeddings no contextuales, se preservaron las formas originales de los tokens tras la limpieza inicial, evitando alteraciones que pudieran afectar a las relaciones distribucionales aprendidas por los modelos. En ambos casos, se implementó una gestión específica de acrónimos y términos clave del dominio financiero. Para ello, se definió una lista `KEEP_TERMS` con términos relevantes (por ejemplo, *ONS*, *UK*, *GDP*) y patrones basados en expresiones regulares para evitar su eliminación o normalización errónea. Asimismo, se estableció una longitud mínima para los tokens alfabéticos, asegurando que la representación final se centrara en contenido semánticamente relevante.

3.1.2. Análisis de resultados




Figura 3: Distribución de longitudes de texto antes y después del preprocesamiento.

En la Figura 3 se muestra la distribución de la longitud de los textos antes y después del preprocesamiento. Se observa una reducción significativa en la longitud media de las noticias, que pasa de 426.9 a 253.6 palabras, mientras que la mediana disminuye de

404 a 245, lo que supone una reducción aproximada del 38.9 %. La forma general de la distribución se mantiene, aunque desplazada hacia valores menores, lo que indica que el proceso eliminó principalmente ruido y redundancia sin alterar el contenido semántico principal de los textos.

ANÁLISIS TOKEN POR TOKEN (primeros 60 tokens):				
TOKEN	LEMMA	POS	¿MANTENER?	RAZÓN
the	the	DET	NO	Stopword
uk	uk	PROPN	SÍ	KEEP_TERMS
jobs	job	NOUN	SÍ	Palabra válida
market	market	NOUN	SÍ	Palabra válida
continues	continue	VERB	SÍ	Palabra válida
to	to	PART	NO	Stopword
show	show	VERB	NO	Stopword
signs	sign	NOUN	SÍ	Palabra válida
of	of	ADP	NO	Stopword
weakness	weakness	NOUN	SÍ	Palabra válida
,	,	PUNCT	NO	Puntuación/Espacio
with	with	ADP	NO	Stopword
pay	pay	NOUN	SÍ	Palabra válida
growth	growth	NOUN	SÍ	Palabra válida
...				

Figura 4: Ejemplo de análisis token a token tras el preprocesamiento aplicado.

En cuanto al análisis a nivel de token, ilustrado en la Figura 4, se puede observar que el pipeline diferencia correctamente entre términos informativos y ruido lingüístico. Palabras funcionales como *the*, *to* u *of* se eliminan como *stopwords*, mientras que términos sustantivos relevantes para el dominio financiero (por ejemplo, *market*, *growth*, *weakness*) se preservan. Asimismo, el mecanismo de *KEEP_TERMS* garantiza la conservación de acrónimos y términos clave del dominio, evitando su eliminación errónea durante el preprocesamiento. En conjunto, el proceso permitió alcanzar un equilibrio adecuado entre limpieza y retención semántica, reduciendo el tamaño efectivo del vocabulario en torno a un 40 % sin pérdida apreciable de información relevante.

3.2 Preprocesamiento para modelos contextuales

En la creación de embeddings contextuales, cada palabra obtiene una representación vectorial distinta en función del contexto en el que aparece. Por este motivo, es necesario trabajar con textos lo más naturales y completos posible, de manera que el modelo pueda capturar adecuadamente la información contextual. En consecuencia, el preprocesamiento aplicado a este tipo de representaciones se diseñó de forma deliberadamente simple, centrándose en una tokenización precisa y una normalización básica, y evitando prácticas como la eliminación de *stopwords*, el *stemming* o la lematización, que podrían alterar la estructura semántica del texto.

3.2.1. Tokenización para BERT

A diferencia de modelos como ELMo, que emplean tokenización a nivel de palabra, los modelos basados en arquitecturas Transformer como BERT [6] utilizan un proceso de tokenización por subpalabras (*subword tokenization*), implementado mediante algoritmos como WordPiece [22]. Este proceso debe realizarse necesariamente con el tokenizador específico con el que fue entrenado el modelo, garantizando así la coherencia entre la tokenización y los pesos aprendidos durante el preentrenamiento.

En este caso, se optó por utilizar el modelo *bert-base-multilingual-cased*, un modelo que permite trabajar con textos multilingües manteniendo la distinción entre mayúsculas y minúsculas. Durante el proceso de tokenización se aplicó *padding* con el objetivo de obtener representaciones de longitud uniforme, facilitando el trabajo con matrices de entrada de tamaño fijo. Asimismo, se limitó la longitud máxima de los textos a 512 tokens, que constituye el tamaño máximo de entrada admitido por el modelo.

Si bien el truncate de textos que superan este límite implica la pérdida de parte de la información y, por tanto, de contexto potencialmente relevante, esta decisión resulta razonable en el dominio trabajado. En noticias financieras, los fragmentos más informativos suelen concentrarse en el titular y en las primeras frases del artículo, por lo que este enfoque resulta adecuado para tareas como clasificación de documentos o reconocimiento de entidades en textos relativamente acotados.

3.2.2. Tokenización para FinBERT

Dentro de la estructura del proyecto, una de las tareas principales consiste en la extracción de eventos y términos financieros mediante técnicas de *Named Entity Recognition*. Para ello se empleó un modelo especializado del dominio financiero, concretamente FinBERT [1], entrenado sobre textos económicos y financieros a partir de la arquitectura BERT y adaptado tanto en vocabulario como en pesos a la terminología propia de noticias, informes y análisis del ámbito económico.

El proceso de tokenización en FinBERT constituye un paso esencial para garantizar una correcta interpretación del lenguaje financiero. Al igual que BERT, FinBERT utiliza tokenización por subpalabras mediante el algoritmo WordPiece, si bien este ha sido entrenado sobre un corpus financiero especializado, lo que permite una mejor representación de términos técnicos y expresiones propias del dominio.

Este modelo permite identificar un conjunto amplio de tipos de entidades, incluyendo personas, organizaciones, localizaciones, fechas y cantidades monetarias, lo que lo hace especialmente adecuado para tareas de extracción de información en textos financieros. De forma análoga a BERT, el proceso de tokenización mapea cada subtoken a su identificador numérico correspondiente en el vocabulario del modelo, aplica *padding* mediante el token especial [PAD] para secuencias cortas y limita la longitud máxima de entrada a 512

tokens.

4 Generación de Embeddings

4.1 Métodos de representación tradicionales

Para comenzar el proceso de vectorización del corpus, se aplicaron dos enfoques clásicos: Bag-of-Words (BoW) y TF-IDF (Term Frequency-Inverse Document Frequency). En primer lugar, mediante el modelo Bag-of-Words, cada documento se representó como un vector de frecuencias, contabilizando el número de apariciones de cada término dentro del vocabulario total. Este enfoque, aunque más sencillo, permitió obtener una primera representación del corpus, con la que se analizó la distribución de términos y el grado de variabilidad léxica entre noticias. Los resultados reflejaron un vocabulario extenso, lo que resulta coherente al tratarse de textos financieros procedentes de distintas fuentes, traducándose en una alta dispersión de términos poco recurrentes.

Posteriormente, se generó la matriz TF-IDF, que ajusta las frecuencias obtenidas en BoW en función de la relevancia global de cada palabra en el conjunto de documentos. Este método reduce el peso de los términos más comunes y resalta aquellos que aportan información más específica sobre cada noticia. La matriz resultante presentó unas dimensiones de (5160×104149) y una dispersión del 96.5 %, lo que implica que solo un 3.5 % de las celdas contienen valores distintos de cero. Este grado de *sparsity* es habitual en representaciones TF-IDF aplicadas a corpus amplios y diversos como es el caso.

Cabe destacar que, para la construcción de BoW y TF-IDF, se utilizó el corpus preprocesado mediante el pipeline lematizado descrito previamente, dado que en estos métodos basados en frecuencias la reducción morfológica contribuye a disminuir la dimensionalidad del vocabulario y mejorar la interpretabilidad de la representación.

4.1.1. Análisis comparativo de resultados

Mediante un análisis conjunto de ambos métodos se observaron diferencias claras en la forma en que representan la información. El modelo BoW refleja de manera más directa la frecuencia absoluta de las palabras, por lo que tiende a estar dominado por términos muy comunes (*market*, *company*, *stock*, etc.). Por el contrario, TF-IDF reduce el impacto de esas palabras frecuentes, elevando el peso de términos más distintivos como *merger*, *quarterly* o *guidance*, asociados a eventos o reportes financieros más concretos.




Figura 5: Términos más frecuentes según TF-IDF.

A partir de la comparación de las matrices de similitud generadas con ambos modelos, se observó que TF-IDF ofrece una mayor capacidad discriminativa entre documentos. En la Figura 6 se muestra la similitud coseno entre un subconjunto de noticias, donde los valores más altos corresponden a textos con temáticas similares (por ejemplo, resultados financieros o anuncios tecnológicos).




Figura 6: Comparativa de similitud coseno entre BoW y TF-IDF.

En conjunto, BoW permite caracterizar la frecuencia y presencia de términos de forma global, mientras que TF-IDF proporciona una representación más refinada para capturar la relevancia de cada palabra en el contexto del corpus. La combinación de ambos métodos sirvió como base sólida para entender la estructura léxica del conjunto de noticias y preparar las etapas posteriores de representación mediante embeddings.

4.2 Embeddings no contextuales

Tras la representación tradicional mediante TF-IDF, se entrenaron y analizaron distintos modelos de embeddings no contextuales, con el objetivo de obtener representaciones vectoriales más densas y semánticamente informativas para el léxico del corpus. A diferencia de BoW y TF-IDF, estos modelos representan cada palabra mediante un vector denso de dimensión fija aprendido a partir de patrones de co-ocurrencia.

Para estos modelos se utilizó el corpus preprocesado sin lematización, preservando las formas superficiales de las palabras, dado que los embeddings distribucionales capturan relaciones semánticas a partir de las co-ocurrencias en su forma observada y una normalización excesiva puede afectar a la calidad de las asociaciones aprendidas.

4.2.1. Modelos implementados

- **Word2Vec** [14]: se entrenaron las variantes Continuous Bag-of-Words (CBOW) y Skip-gram con vectores de 300 dimensiones, empleando una ventana de contexto de tamaño 5 y un umbral mínimo de frecuencia (*min_count*) para reducir ruido léxico. Los modelos se entrenaron desde cero sobre el corpus preprocesado, de modo que las relaciones de co-ocurrencia capturasen asociaciones propias del lenguaje económico y bursátil.
- **FastText** [3]: se utilizó su versión Skip-gram para aprovechar la capacidad de generar embeddings a partir de n-gramas de caracteres. Esta propiedad resulta especialmente útil en un corpus financiero, que contiene numerosos acrónimos y combinaciones alfanuméricas (*AI-driven*, *Q3_earnings*, *NASDAQ100*), mejorando la representación de términos poco frecuentes.
- **GloVe** [15]: se cargó el modelo preentrenado *glove.6B.300d*, basado en Wikipedia y Gigaword, adaptándolo al formato Word2Vec para emplearlo en la misma interfaz de análisis. Aunque no se entrenó sobre datos financieros, se utilizó como punto de comparación frente a los modelos entrenados con el corpus propio.

En conjunto, los modelos se evaluaron cualitativamente mediante consultas de similitud semántica entre palabras clave (por ejemplo, *inflation*, *interest*, *recession*) y explorando los términos más próximos en el espacio vectorial. Se esperaba que Word2Vec capturase relaciones distribucionales ajustadas al corpus y que FastText ofreciera una mayor cobertura y robustez frente a variaciones morfológicas y acronímicas.

4.2.2. Cobertura y calidad de los embeddings

Con el objetivo de evaluar la adecuación de los embeddings al dominio, se analizó la cobertura del vocabulario de cada modelo, entendida como la proporción de tokens del

corpus que disponen de representación vectorial. Para ello se calculó la tasa de palabras fuera de vocabulario (Out-of-Vocabulary, OOV [12]) según:

$$OOV(\%) = 100 \times \frac{N_{\text{tokens no representados}}}{N_{\text{tokens totales}}}$$

Implementamos esta métrica recorriendo los tokens del corpus y comprobando su presencia en el vocabulario de cada modelo mediante estructuras *KeyedVectors*. Los resultados se muestran en la Tabla 3.

Cuadro 3: Comparativa de cobertura y tamaño de vocabulario entre modelos no contextuales.

Modelo	Dim.	Vocabulario	OOV (%)	Tipo de entrenamiento
Word2Vec (CBOW)	300	102,341	14.2	Entrenado sobre corpus propio
Word2Vec (Skip-gram)	300	101,587	13.8	Entrenado sobre corpus propio
FastText (Skip-gram)	300	104,918	8.5	Entrenado sobre corpus propio
GloVe (6B, 300d)	300	400,000	13.1	Preentrenado (Wikipedia + Gigaword)

Se puede apreciar que los modelos entrenados sobre el propio corpus alcanzan una cobertura superior al modelo GloVe preentrenado, al estar más ajustados al léxico financiero. Asimismo, FastText obtiene la mejor cobertura global, atribuible a su capacidad para generar representaciones a partir de subpalabras, reduciendo la proporción de términos fuera de vocabulario (OOV). Este comportamiento confirma su idoneidad para un conjunto de noticias caracterizado por la abundancia de acrónimos, variaciones morfológicas y nombres propios del sector.

4.2.3. Análisis semántico y visualización

Para evaluar la coherencia semántica, se analizaron las palabras más similares a términos clave del dominio (*market*, *stock*, *inflation*, *profit*, *ai*, *interest_rate*, *federal_reserve*), así como analogías del tipo $a - b + c$. Los modelos Word2Vec y FastText capturaron relaciones coherentes como:

- $market \rightarrow stock, equity, bond, share$
- $inflation \rightarrow prices, wages, interest_rate$.

Además, mediante reducción de dimensionalidad (PCA y t-SNE) se comprobó que las agrupaciones léxicas formadas por términos financieros son coherentes y separables entre categorías como tecnología, macroeconomía o mercados bursátiles.

4.2.4. Conclusiones y modelo más adecuado

De los métodos analizados, **FastText** mostró el mejor equilibrio entre cobertura, robustez frente a variaciones léxicas y calidad semántica. Su capacidad para generalizar a partir de subpalabras resulta especialmente útil en este dominio, donde aparecen siglas, abreviaturas y tecnicismos (por ejemplo, *YoY*, *EPS*, *Fed*, *Nasdaq*, *AI-driven*). Por otro lado, los embeddings **Word2Vec** entrenados sobre el propio corpus aportan una semántica más ajustada al contexto de las noticias, resultando adecuados como base para análisis y tareas posteriores. Finalmente, **GloVe** sirvió como punto de comparación al ser un modelo preentrenado sobre un dominio generalista, pero con menor adecuación al lenguaje técnico del sector.

En consecuencia, para las siguientes fases del proyecto se emplearon los embeddings **FastText (Skip-gram)** y **Word2Vec (Skip-gram)** como base para las representaciones vectoriales, al ofrecer el mejor rendimiento y adaptabilidad al dominio.

4.3 Embeddings contextuales

En esta fase se generaron embeddings contextuales a partir de modelos basados en BERT, con el objetivo de obtener representaciones vectoriales sensibles al contexto para palabras y documentos. Los datos tokenizados se agruparon en lotes (*batches*) de 32 textos y se procesaron en modo inferencia. Para cada lote, los tensores `input_ids` y `attention_mask` se introdujeron en el modelo, obteniendo como salida el `last_hidden_state`, que contiene las representaciones finales para todos los tokens.

Dado que el objetivo del proyecto requiere tanto representaciones a nivel de token (por ejemplo, para NER) como representaciones a nivel de documento (por ejemplo, para clasificación), se adoptaron dos estrategias complementarias:

- Embeddings a nivel de token, donde cada subtoken se representa por un vector de 768 dimensiones.
- Embeddings a nivel de documento, obtenidos a partir del embedding asociado al token especial, `[CLS]`, diseñado para capturar la información global de la secuencia de entrada

4.3.1. Embeddings BERT

Se generaron embeddings contextuales utilizando el modelo BERT Multilingüe (*bert-base-multilingual-cased*), con el objetivo de ilustrar el proceso general de obtención de representaciones mediante Transformers. Los embeddings obtenidos se almacenaron en formato Parquet debido a su eficiencia en compresión y lectura de grandes estructuras numéricas.

4.3.2. Embeddings FinBERT

En esta etapa se generaron embeddings contextuales específicos del dominio financiero utilizando el modelo FinBERT, concretamente la versión *boltauix/NeuroBERT-NER* disponible en Hugging Face. FinBERT es una adaptación de la arquitectura BERT al contexto financiero, entrenado con documentos procedentes de informes, noticias y comunicados económicos. Su arquitectura mantiene la estructura original de BERT base (12 capas Transformer y dimensión de embedding de 768), incorporando conocimiento semántico especializado.

En cada lote de datos, los tensores `input_ids` y `attention_mask` se pasaron al modelo FinBERT y se obtuvieron los vectores de salida. Para obtener una representación más estable y semánticamente rica a nivel de token, se aplicó *layer pooling* calculando la media de las cuatro últimas capas (*last4_mean*). En paralelo, para la representación a nivel de documento se utilizó el embedding del token [CLS] (opcionalmente tras el mismo esquema de *pooling*), permitiendo disponer de un vector global para tareas de clasificación.

Cuadro 4: Comparativa de representación de embeddings contextuales.

Modelo	Nivel	Dimensiones	Estrategia
BERT	Token / Documento	768	<code>last_hidden_state</code> + [CLS]
FinBERT	Token / Documento	768	<i>last4_mean</i> + [CLS]

4.4 Lecciones aprendidas

El desarrollo de esta fase del proyecto permitió identificar la importancia de adaptar las decisiones de preprocesamiento y representación al tipo de modelo empleado. En una primera aproximación se cometieron algunos errores conceptuales, como aplicar lematización a embeddings no contextuales o no emplear el token [CLS] para la representación global de textos en modelos basados en BERT.

La revisión de estos aspectos mostró que la lematización resulta adecuada únicamente en métodos tradicionales basados en frecuencias (BoW y TF-IDF), donde contribuye a

reducir la dimensionalidad y mejorar la interpretabilidad, mientras que en embeddings distribucionales puede degradar las relaciones semánticas aprendidas. Del mismo modo, el uso correcto del token [CLS] se reveló esencial para obtener representaciones coherentes a nivel de documento en modelos contextuales.

Realizar estas correcciones a fallos hechos en primera instancia permitieron definir un pipeline más consistente y alineado de cara a las siguientes secciones.

5 Primera Iteración del Modelo

En esta sección del proyecto se trabaja una primera iteración completa del proyecto, centrada en la resolución de dos tareas principales: la clasificación de textos por temática y la generación de resúmenes, comparando enfoques basados en Shallow Machine Learning con modelos de Deep Learning, analizando sus diferencias en términos de rendimiento, capacidad de generalización y complejidad. Esta iteración supone el primer approach específico a tareas de clasificación y generación de texto, lo que permite evaluar las ventajas y limitaciones del NLP aplicado a noticias financieras.

5.1 Modelos y enfoques utilizados

Para la tarea de clasificación de noticias financieras por temática, se han explorado enfoques tanto de Shallow Machine Learning como de Deep Learning, con el objetivo de comparar su comportamiento y rendimiento bajo distintas representaciones del texto.

5.1.1. Shallow Learning

En primer lugar, se implementaron modelos tradicionales de supervised learning, concretamente un Multiclass Logistic Regressor y un Linear Support Vector Machine (SVM). Ambos clasificadores se entrenaron utilizando diferentes representaciones vectoriales del texto: TF-IDF, como enfoque basado en conteo, y Word2Vec, como representación densa. Esta combinación permitió analizar cómo influye la forma de representar el texto en modelos lineales clásicos.

5.1.2. Deep Learning

En cuanto a los enfoques de Deep Learning, para la clasificación de textos se han diseñado tanto una red convolucional (CNN) como una Bi-LSTM.

- **CNN:** Compuesta por una capa Conv1D con 128 filtros y tamaño de kernel 5, encargada de extraer patrones locales del texto, seguida de una capa GlobalMax-Pooling1D para la reducción de dimensionalidad. A continuación, se incluye una capa densa intermedia de 64 neuronas con un Dropout del 50 % como mecanismo

de regularización, y una capa de salida softmax con 5 neuronas para la clasificación multiclase. El modelo fue evaluado utilizando tanto embeddings Word2Vec entrenados sobre el corpus como vectores preentrenados de Google News.

- **Bi-LSTM:** 256 neuronas, capaz de modelar dependencias contextuales tanto hacia adelante como hacia atrás en la secuencia. La salida de la Bi-LSTM se procesó mediante un bloque de pooling, seguido de una capa densa intermedia de 64 neuronas y una capa de salida softmax para clasificación multiclase.

Por otro lado, para la generación automática de titulares o resúmenes, se ha implementado una arquitectura basada en modelos Sequence-to-Sequence (Seq2Seq) con mecanismo de atención, implementado mediante unidades GRU por su mayor eficiencia computacional y menor riesgo de sobreajuste frente a LSTM en datasets de tamaño medio.

- Para evitar que toda la información del texto de entrada quede comprimida en una única representación fija, se incorporó un mecanismo de atención de Bahdanau, que facilita el acceso selectivo a diferentes fragmentos del artículo durante la generación del titular.
- Para ello se han evaluado distintas configuraciones de embeddings, concretamente FastText y BERT, tanto en modo frozen como fine-tuned, con el objetivo de analizar el impacto de embeddings estáticos frente a embeddings adaptados al dominio.

5.2 Primeros resultados obtenidos

5.2.1. Clasificación de texto

En el caso de la clasificación temática, los modelos de *Shallow Machine Learning* han mostrado un rendimiento muy competitivo. En particular, la combinación de **TF-IDF con Linear SVM** ha obtenido los mejores resultados globales, alcanzando las mayores métricas de accuracy y macro-F1 tanto en validación como en test.

El **Multiclass Logistic Regressor** también ha mostrado un comportamiento estable y consistente con TF-IDF, obteniendo resultados ligeramente inferiores a la SVM pero manteniendo un buen equilibrio entre accuracy y macro-F1

Word2Vec mostro peores resultados que **TF-IDF**, ya que pierde información léxica clave para la discriminación temática. El uso de **SVM** mejora ligeramente frente a Logistic Regression con esta representación, pero sin igualar a TF-IDF, y el subsampling resultó perjudicial al reducir la variabilidad del entrenamiento.

En los modelos de **Deep Learning**, tanto la **CNN** como la **Bi-LSTM** lograron aprender patrones relevantes a partir de la representación secuencial con embeddings Word2Vec. No obstante, en esta primera iteración no superaron de forma clara a los mejores modelos shallow, lo que sugiere que, con el tamaño de dataset disponible, los

enfoques lineales bien ajustados siguen siendo una referencia muy fuerte para la tarea de clasificación.




Figura 7: Resultados de tecnicas Shallow ML




Figura 8: Resultados de tecnicas Deep Learning

5.2.2. Generación de resúmenes

Para la tarea de generación de titulares se evaluó una arquitectura Seq2Seq con mecanismo de atención, comparando distintas configuraciones de embeddings mediante métricas **ROUGE-1** y **ROUGE-2**, complementadas con un **análisis cualitativo** de las salidas generadas. Las métricas ROUGE-1 y ROUGE-2 se han utilizado como una medida de apoyo para la evaluación cuantitativa de la generación de titulares, ya que comparan la superposición léxica entre el resumen generado y el heading original del texto, y esta evaluación presenta limitaciones, dado que la columna heading no muestra un resumen

exhaustivo del contenido. Por este motivo, los valores de ROUGE deben interpretarse como un indicador orientativo, complementado necesariamente con un análisis cualitativo de las salidas generadas.

- **FastText Frozen:** Mejor rendimiento global en ROUGE. Generación de titulares coherentes, capturando correctamente entidades y acciones relevantes. El uso de embeddings estáticos actúa como un regularizador eficaz en datasets de tamaño medio.
- **FastText Fine-tuned:** Caída significativa del rendimiento. Evidencia de inestabilidad durante el entrenamiento y pérdida de estructura en las salidas.
- **BERT Frozen:** Resultados intermedios, superiores a las variantes fine-tuned. No supera a FastText, posiblemente por la proyección de embeddings de alta dimensionalidad a un decodificador recurrente más reducido.
- **BERT Fine-tuned:** No produce resultados válidos debido a limitaciones computacionales durante el entrenamiento.

FastText Frozen genera titulares con estructura reconocible. Las configuraciones con peor rendimiento presentan repeticiones, bucles léxicos y salidas incoherentes.

5.3 Lecciones aprendidas

El análisis de la primera iteración permitió identificar deficiencias metodológicas hacían poco fiables a la comparativa entre modelos. A continuación, se detallan los errores detectados y las acciones correctivas aplicadas:

- **Estandarización del Protocolo de Evaluación:** Error: Se detectó una falta de homogeneidad al usar un split fijo para Shallow Learning frente a un cross-validation para Deep Learning, lo que impedía una comparación justa.
 - **Solución:** Se ha unificado mediante un split stratified de train y test para todos los modelos. Esto garantiza que se mantenga la misma distribución de clases en ambos subconjuntos y asegura la reproducibilidad de los experimentos.
- **Homogeneización y Reporte de Métricas:**
 - Error: La falta de métricas clave (especialmente macro-F1) en el reporte de las redes neuronales dificultaba la evaluación objetiva frente a los modelos clásicos.
 - Solución: Se han integrado y reportado explícitamente las métricas de accuracy y macro-F1 en todos los experimentos, asegurando una trazabilidad completa desde los notebooks hasta la documentación final.

6 Segunda iteración

6.1 Text Summarization

Para la tarea de generación de resúmenes o titulares de las noticias financieras y facilitar su consumo rápido, en esta iteración se ha implementado un flujo completo de pasos para resúmenes reformulando el contenido con palabras y frases propias, es decir, de forma abstractiva. A diferencia de los métodos extractivos, este enfoque permite generar frases nuevas que condensan el contenido semántico original.

Para esta tarea, se seleccionó la arquitectura T5 (Text-to-Text Transfer Transformer) [17], específicamente la versión optimizada **falconsai/text_summarization**. La elección de T5 responde a su naturaleza Sequence-to-Sequence (Seq2Seq), la cual ha sido pre-entrenada, donde tanto el input como el output son siempre cadenas de texto. Esto significa una ventaja frente a modelos basados únicamente en embeddings o clasificadores simples, ya que está diseñado explícitamente para tareas de generación y condensación de texto.

6.1.1. Implementación y Procesamiento

La implementación se realizó mediante la librería transformers de HuggingFace, definiendo una función de procesamiento que integra la limpieza de texto, tokenización y generación proporcionada por el modelo. El flujo aplica una estrategia de procesamiento por lotes (batch processing) con un tamaño de *batch* = 8, optimizando así el uso de la memoria de la GPU y reduciendo los tiempos de latencia durante la inferencia.

6.1.2. Evaluación y Comparativa con Iteraciones Previas

Para cuantificar la calidad de los resúmenes, se utilizaron las métricas **ROUGE-1** y **ROUGE-L**. Es importante mencionar que la evaluación se realizó comparando los resúmenes generados frente a los titulares de las noticias originales. Aunque esta metodología sirve como una evaluación auxiliar relativa para comparar modelos, se ha procurado interpretar los resultados cautela, ya que un titular no siempre contiene toda la información de un resumen ideal.

- En esta tabla se muestran los resultados y la comparativa de rendimiento frente a los modelos de la primera iteración (FastText y BERT):

Cuadro 5: Resultados ROUGE de modelos en la iteración previa.

Modelo (Iteración Pre- via)	ROUGE-1	ROUGE-2
FastText Frozen	0.2229	0.0824
FastText Fine-tuned	0.0522	0.0014
BERT Frozen	0.1302	0.0288
BERT Fine-tuned	0.0000	0.0000

Cuadro 6: Resultado ROUGE-1 promedio del modelo en la iteración actual.

Modelo (Iteración Actual)	ROUGE-1 Promedio
T5 (falconsai)	0.2088

- A pesar de que FastText Frozen presenta un ROUGE-1 ligeramente superior (0.22), T5 demuestra una estabilidad significativamente mayor.
- Mientras que FastText y BERT sufrieron colapsos de rendimiento tras el fine-tuning (llegando a 0.0 en el caso de BERT), T5 mantiene una coherencia generativa constante.
- La superioridad de T5 en la métrica ROUGE-L (que evalúa la subsecuencia común más larga) confirma que el modelo no solo captura palabras clave, sino que preserva la estructura y el orden global del texto, superando la coherencia local limitada que ofrecían los n-gramas de los modelos previos.

6.1.3. T5 vs. Inferencia Local con LLM (Ollama)

Como tarea adicional y con el fin de explorar arquitecturas de última generación, se integró un **modelo cuantizado de LLaMA 3.2** a través de la API de Ollama. Para ello, se diseñó un prompt específico orientado a la extracción de hechos clave (números, fechas y actores) en un formato estrictamente informativo de cuatro frases:

- "Summarize the following text news in 2 sentences without any additional commentary or explanation. "
- "Focus on the key facts (numbers, dates, actors)."
- ".Avoid opinions and just output the summary."
- "Don't include any introductory phrases like 'The summary is' or 'In summary', just the plain summary."

La comparación de el modelo T5 con el uso de ollama 3.2 mostraban 2 conclusiones relevantes:

1. **Rendimiento Pico vs. Estabilidad:** T5 alcanza puntuaciones máximas más altas, pero de forma intermitente (varianza de 0.2831 entre su mejor y peor caso). Esto podría relacionarse con una dependencia mayor de la similitud estructural entre la noticia y el titular.
2. **Consistencia Generalista:** LLaMA 3.2, a pesar de tener un ROUGE-1 promedio ligeramente menor, muestra un comportamiento mucho más constante (varianza de solo 0.1208). Esta estabilidad es propia de los modelos de lenguaje de gran escala (LLM), ya que su capacidad de comprensión generalista les permite procesar diversos estilos de noticias sin caídas pronunciadas de calidad.

6.2 Clasificación de Textos

En esta segunda iteración, para cumplir con la tarea de clasificación temática de noticias, se trató de evaluar el impacto del conocimiento específico del dominio financiero. Para ello, se diseñó un experimento comparativo entre modelos de lenguaje preentrenados con características complementarias: un modelo generalista, entrenado sobre grandes volúmenes de texto de dominio abierto, y un modelo especializado, entrenado explícitamente sobre corpus financieros. Este planteamiento sigue la línea de trabajos previos que analizan hasta qué punto la especialización de dominio aporta ventajas reales frente a modelos generalistas en tareas de clasificación multi-clase [2].

Como punto de partida, se analizaron estudios recientes sobre clasificación de texto en el dominio financiero. En particular, el estudio de Arslan et al. [2] muestra que, entre los modelos genéricos evaluados (BERT, DistilBERT, RoBERTa, XLNet y XLM), *RoBERTa* obtiene de forma consistente los mejores resultados en tareas de clasificación multi-clase, tanto en datasets financieros como no financieros (se puede observar en la Tabla 4 del paper citado). Este comportamiento se atribuye a un preentrenamiento más prolongado y a modificaciones en el procedimiento de entrenamiento respecto a BERT original [13].

No obstante, en una fase preliminar del proyecto se constató que el uso de modelos del tamaño completo de RoBERTa suponía un coste computacional elevado en el entorno disponible. Estas limitaciones prácticas hicieron inviable la realización de múltiples experimentos y ajustes de hiperparámetros con RoBERTa base.

Por este motivo, y siguiendo una estrategia análoga a la adoptada en el estudio mencionado anteriormente, en el cual se emplea *DistilBERT* como alternativa eficiente a BERT manteniendo un rendimiento comparable, se optó por utilizar *DistilRoBERTa* como modelo generalista de referencia. DistilRoBERTa es una versión destilada de RoBERTa que reduce aproximadamente un 40 % el tamaño del modelo y mejora significativamente la velocidad de inferencia, conservando alrededor del 97 % de la capacidad de comprensión

lingüística del modelo original [18]. Esta elección permitió equilibrar de forma adecuada el compromiso entre rendimiento y coste computacional, haciendo viable la realización de más pruebas en caso de ser necesario.

Como contraparte especializada, se seleccionó *FinBERT*, concretamente la versión publicada por ProsusAI en HuggingFace [16] y preentrenada sobre el corpus TRC2-financial, que contiene más de 46.000 documentos financieros procedentes de Reuters [1]. FinBERT extiende la arquitectura BERT mediante un preentrenamiento adicional en textos económicos y financieros, de esta manera incorpora expresiones léxicas y semánticas propias de este dominio. Aunque el modelo se publica originalmente orientado al análisis de sentimiento financiero, su encoder subyacente resulta especialmente adecuado para evaluar si la especialización de dominio aporta ventajas en tareas de clasificación temática de noticias financieras.

De este modo, la comparación entre DistilRoBERTa y FinBERT permite analizar empíricamente dos estrategias habituales del NLP aplicado: el uso de modelos generalistas robustos y eficientes frente a modelos especializados en el dominio, manteniendo constante el procedimiento de entrenamiento y evaluación para aislar el efecto del conocimiento de dominio en el rendimiento final del sistema.

6.2.1. Entrenamiento y fine-tuning

Para adaptar ambos modelos a la tarea de clasificación temática, se empleó una estrategia de Transfer Learning concretamente mediante un proceso de *fine-tuning* bajo un mismo esquema experimental, con el objetivo de garantizar una comparación justa entre las dos arquitecturas. En ambos casos se reutilizó el encoder preentrenado y se sustituyó la capa de clasificación original por una nueva cabeza adaptada al número de categorías del problema.

Concretamente, la capa de salida de cada modelo fue reemplazada por una cabeza de clasificación con cinco neuronas, correspondientes a los cinco tópicos definidos mediante el modelado no supervisado descrito en la sección ??.. Esta adaptación resulta especialmente necesaria en el caso de FinBERT, dado que su configuración original contempla únicamente tres categorías asociadas al análisis de sentimiento financiero.




Figura 9: Esquema conceptual del proceso de fine-tuning aplicado a FinBERT. La cabeza de clasificación original, orientada al análisis de sentimiento (tres clases), se sustituye por una nueva capa adaptada a los cinco tópicos definidos en el proyecto, manteniendo el encoder preentrenado y ajustando sus pesos durante el entrenamiento.

Como input a los modelos se utilizó una concatenación del titular (*headline*) y el resumen (*summary*) de cada noticia. Esta decisión permite capturar la información esencial del evento descrito sin exceder el límite máximo de 512 tokens impuesto por las arquitecturas Transformer, evitando al mismo tiempo el ruido textual presente en el cuerpo completo de los artículos.

El conjunto de datos se dividió en dos particiones fijas, asignando el 70 % de las instancias al conjunto de entrenamiento y el 20 % al conjunto de test. Esta partición se mantuvo constante para ambos modelos con el objetivo de asegurar que las diferencias observadas en el rendimiento final se deban exclusivamente a la arquitectura y al conocimiento de dominio incorporado, y no a variaciones en los datos utilizados durante el entrenamiento o la evaluación.

En cuanto a los hiperparámetros de entrenamiento, se configuró un proceso de aprendizaje de tres epochs, siguiendo las recomendaciones empíricas de Arslan et al. [2], quienes indican que para tareas de clasificación financiera los modelos suelen alcanzar un punto de convergencia adecuado entre la tercera y la quinta epoch. Para garantizar la estabilidad del entrenamiento en el entorno computacional disponible, se empleó un tamaño batch size reducido (entre 4 y 8 muestras) y un learning rate de 2×10^{-5} , permitiendo un ajuste progresivo del modelo y reduciendo el riesgo de overfitting y degradación del conocimiento previamente aprendido durante el preentrenamiento.

Este procedimiento permitió adaptar ambos modelos a la tarea objetivo manteniendo constantes las condiciones de entrenamiento, facilitando así una evaluación comparativa justa y rigurosa del impacto del conocimiento de dominio en la clasificación temática de noticias financieras.

6.2.2. Comparativa de resultados de los Modelos de Transformers

Una vez finalizado el proceso de entrenamiento y *fine-tuning*, se evaluó el rendimiento de ambos modelos sobre el conjunto de *test* utilizando métricas estándar en tareas de clasificación multi-clase. En primer lugar, se realizó un análisis detallado de los resultados obtenidos por cada modelo de forma individual, con el objetivo de identificar patrones de acierto y error a nivel de categoría. Posteriormente, se llevó a cabo un análisis comparativo de las métricas globales, con el fin de evaluar el impacto del preentrenamiento especializado en corpus financieros frente a un modelo generalista.

Cuadro 7: Resultados por clase obtenidos con DistilRoBERTa en el conjunto de test

Categoría	Precision	Recall	F1-score	Support
Business Growth and AI	0.7913	0.8864	0.8361	308
Financial and Market News	0.8770	0.8363	0.8562	452
Informal Language	0.6923	0.6000	0.6429	30
Quantum Computing and Military Tech	0.6875	0.5500	0.6111	20
Stock Market and Trading	0.8037	0.7748	0.7890	222

Se puede apreciar que DistilRoBERTa tiene un rendimiento sólido en las clases mayoritarias del corpus, especialmente en *Business Growth and AI* y *Financial and Market News*, donde alcanza valores elevados de *recall* y *F1-score* con 0.88, 0.83 y 0.83 y 0.85 respectivamente. Este comportamiento indica que el modelo generalista es capaz de capturar los patrones semánticos relevantes de contextos más concretos una vez siendo fine-tuneado en un número suficiente de ejemplos de entrenamiento. En la categoría *Stock Market and Trading*, el modelo mantiene también un desempeño consistente con valores de 0.77 y 0.78, lo que sugiere una buena capacidad de generalización en el dominio concreto del proyecto con vocabulario recurrente y una estructura relativamente homogénea.

Por el contrario, en las categorías más minoritarias del corpus, como *Informal Language* y *Quantum Computing and Military Technology*, se observa una reducción notable del rendimiento, reflejada en valores inferiores de *F1-score*, cayendo casi un 0.2 respecto a las demás. Este efecto puede atribuirse principalmente al desbalanceo de clases identificado durante el EDA, ya que el reducido número de ejemplos limita la capacidad del modelo para aprender representaciones discriminativas robustas, incluso aún cuando se aplica un *split* estratificado para tratar de preservar la distribución original de etiquetas entre los conjuntos de entrenamiento y test.

Cuadro 8: Resultados por clase obtenidos con FinBERT en el conjunto de test

Categoría	Precision	Recall	F1-score	Support
Business Growth and AI	0.8354	0.8896	0.8616	308
Financial and Market News	0.8593	0.8783	0.8687	452
Informal Language	0.6786	0.6333	0.6552	30
Quantum Computing and Military Tech	0.8000	0.4000	0.5333	20
Stock Market and Trading	0.8480	0.7793	0.8122	222

En el caso de FinBERT, los resultados muestran comportamiento diferenciado en aquellas categorías que se podrían considerar más estrechamente vinculada al dominio financiero. Tal y como se observa en la Tabla 8, el modelo alcanza valores más elevados de *precision* y *F1-score* en categorías como *Business Growth and AI* y *Financial and Market News*, lo que sugiere que el preentrenamiento adicional sobre corpus financieros contribuye a una mejor representación de la terminología especializada y de los patrones propios de este tipo de noticias. Este efecto resulta especialmente apreciable en las clases mayoritarias del corpus, donde el volumen de datos disponible permite explotar de forma más efectiva el conocimiento de dominio adquirido durante el preentrenamiento.

No obstante, este beneficio no se extiende de forma homogénea a todas las categorías. En las clases con menor representación, como *Informal Language* y *Quantum Computing and Military Technology*, el modelo continúa mostrando dificultades significativas, reflejadas principalmente en valores bajos de *recall*. Aunque se observa una mejora en *precision* en la categoría *Quantum Computing and Military Technology*, la escasez de ejemplos sigue siendo un factor limitante clave, impidiendo que el modelo generalice adecuadamente en escenarios con datos insuficientes.

Cuadro 9: Comparativa de métricas globales en el conjunto de test

Métrica	DistilRoBERTa	FinBERT
Accuracy	0.8256	0.8440
Precision (macro avg)	0.7704	0.8043
Recall (macro avg)	0.7295	0.7161
F1-score (macro avg)	0.7471	0.7462
Precision (weighted)	0.8266	0.8433
Recall (weighted)	0.8256	0.8440
F1-score (weighted)	0.8248	0.8417

A la hora de contrastar los resultados, la Tabla 9 resume el rendimiento global de ambos modelos en el conjunto de test. En el corpus empleado en el proyecto podemos observar como FinBERT obtiene mejores resultados en *accuracy* (0.8440 frente a 0.8256) y en todas las métricas ponderadas, alcanzando un *F1-score weighted* de 0.8417 frente

a 0.8248 en DistilRoBERTa. Estas métricas reflejan un ligero mejor desempeño en las clases mayoritarias del corpus, que concentran la mayor parte de las noticias y están estrechamente relacionadas con el dominio financiero. Este resultado es coherente con los análisis por clase, donde FinBERT muestra mejoras consistentes en *Business Growth and AI* y *Financial and Market News*, categorías clave dentro del objetivo del proyecto.

Por el contrario, al analizar las métricas macro, las cuales asignan el mismo peso a todas las categorías independientemente de su tamaño, ambos modelos presentan valores muy similares de *F1-score macro* (0.7471 en DistilRoBERTa y 0.7462 en FinBERT). Asimismo, DistilRoBERTa obtiene un *recall macro* ligeramente superior (0.7295 frente a 0.7161), lo que indica una mayor capacidad relativa para recuperar instancias de clases minoritarias, aunque a costa de una menor precisión global. Este comportamiento está alineado con los análisis individuales, donde ambos modelos muestran dificultades similares en categorías con escasa representación, evidenciando que el desbalanceo del corpus sigue siendo un factor limitante independientemente del preentrenamiento utilizado.

En conjunto, bajo el dataset empleado en el proyecto el modelo con preentrenamiento especializado en corpus financieros aporta una ventaja cuando el objetivo es maximizar el rendimiento en las categorías más representativas y relevantes del dominio. Dado que el proyecto está orientado principalmente a la detección y clasificación de eventos financieros de alto impacto, se optó por seleccionar FinBERT como modelo principal de Transformers para la tarea de clasificación temática, priorizando su mejor rendimiento global y su mayor alineación semántica con el dominio financiero del proyecto.

6.2.3. Comparativa Respecto a los métodos de Shallow y Deep learning

Para concluir la tarea de clasificación temática de textos, resulta necesario contrastar los resultados obtenidos en esta iteración final, basada en arquitecturas Transformer, con los enfoques evaluados en la primera iteración del proyecto. En dicha fase inicial se exploraron tanto modelos de Shallow Machine Learning como arquitecturas de Deep Learning como primera referencia de rendimiento en el corpus en uso.

Con este objetivo, se realiza a continuación una comparativa global que recoge el mejor modelo de cada uno de los enfoques evaluados hasta el momento: el modelo más competitivo de Shallow Machine Learning, el mejor resultado obtenido en Deep Learning durante la primera iteración, y los dos modelos basados en Transformers analizados en esta fase final. Esta comparación permite evaluar de forma conjunta el impacto de la complejidad del modelo y del preentrenamiento de dominio en la tarea de clasificación temática de noticias financieras.

Cuadro 10: Comparativa global de rendimiento entre enfoques de clasificación

Modelo	Accuracy	F1-score (weighted)
Shallow ML (TF-IDF + Linear SVM)	0.8800	0.8800
Deep Learning (CNN + Embeddings propios)	0.8711	0.8679
DistilRoBERTa (fine-tuned)	0.8256	0.8248
FinBERT (fine-tuned)	0.8440	0.8417

Analizando la tabla presentada, se puede apreciar que el mejor modelo de *Shallow Machine Learning*, concretamente la combinación de TF-IDF con Linear SVM, obtiene las métricas más elevadas en términos de *accuracy* y *F1-score weighted*. Este comportamiento es coherente con lo observado en la primera iteración del proyecto, que señaló que los modelos lineales bien ajustados ya resultaban efectivos esta tarea de clasificación temática.

Una posible explicación de este rendimiento superior reside en la propia naturaleza del propio corpus. La clasificación de textos abordada en este proyecto presenta una fuerte correlación entre determinadas palabras clave y las categorías objetivo, lo que favorece a modelos basados en representaciones dispersas como TF-IDF, capaces de explotar directamente la frecuencia y presencia de términos altamente informativos, especialmente cuando los datos proceden de una misma fuente. Además, el desbalanceo de clases identificado durante el EDA contribuye a que estos modelos optimicen mejor el rendimiento global al centrarse en las categorías mayoritarias.

En cuanto a los modelos de Deep Learning desarrollados en la primera iteración, si bien la CNN y la Bi-LSTM lograron capturar patrones secuenciales relevantes, no superaron de forma clara a los enfoques shallow. Este resultado puede atribuirse, entre otros factores, a la mayor complejidad de estas arquitecturas, que requiere un volumen de datos superior para generalizar de forma robusta.

Por su parte, los modelos basados en Transformers, y en particular FinBERT, no alcanzan las mejores métricas absolutas frente al modelo shallow. No obstante, como se menciona en el análisis comparativo previo, FinBERT obtiene mejores resultados que DistilRoBERTa tanto en *accuracy* como en *F1-score weighted*, lo que permite validar parcialmente la hipótesis planteada sobre el impacto del preentrenamiento especializado en corpus financieros, al menos en las clases más representativas del dominio. Estos resultados sugieren que, aunque los Transformers no maximizan las métricas en este escenario concreto, incorporan de base conocimiento semántico más profundo y contextual que resulta relevante para tareas financieras complejas.

En este sentido, la elección final del modelo de clasificación no se basa exclusivamente en la optimización de métricas, sino en una consideración más amplia del objetivo del proyecto. Dado que una de las mejoras a considerar sería ampliar el dataset incorporando

noticias procedentes de otras fuentes financieras o de más categorías, se considera de mayor valor la capacidad de FinBERT para generalizar en escenarios más heterogéneos. Por este motivo, y pese a que los modelos shallow continúan siendo la mayor referencia en términos de rendimiento, se selecciona FinBERT como modelo principal para la tarea de clasificación temática en la versión final del sistema.

6.3 Extracción de Entidades

En esta fase del proyecto, se implementó un sistema de Reconocimiento de Entidades (**NER**) con el fin de extraer información estructurada de las noticias financieras, identificando elementos clave como organizaciones, fechas, valores monetarios y localizaciones.

6.3.1. Arquitectura y Modelo: Neuro-BERT

Para esta tarea se seleccionó el modelo boltuix Neuro-BERT [4], una arquitectura basada en BERT optimizada para la extracción de entidades. El modelo utiliza un enfoque de embeddings por subtoken, lo que permite manejar de manera eficiente el vocabulario fuera de diccionario (Out-of-Vocabulary).

Sobre cada embedding generado, el modelo aplica una cabeza de clasificación lineal que asigna etiquetas siguiendo el **esquema BIO** (Beginning, Inside, Outside). Este estándar de anotación define las categorías de la siguiente manera:

- **B- (Beginning):** Indica que el token es el inicio de una entidad.
- **I- (Inside):** Indica que el token forma parte de la misma entidad pero no es el primero.
- **O- (Outside):** Indica que el token no pertenece a ninguna entidad.

Las etiquetas específicas definidas en este modelo permiten identificar categorías como Person (PER), Organization (ORG), Location (LOC), Date (DAT) y Percentage (PCT), entre otras.

6.3.2. Proceso de Implementación

El flujo de trabajo consistió en la integración del modelo mediante la librería *transformers* y la reutilización de los tokens generados en la segunda entrega (E2). El proceso se estructuró en tres pasos principales:

1. **Importación del modelo y tokenizer:** Carga de los pesos pre-entrenados de Neuro-BERT.
2. **Inferencia:** Aplicación de la cabeza de clasificación sobre los textos de nuestro dataset financiero.

3. **Post-procesado:** Mapeo de los IDs de las etiquetas a sus correspondientes etiquetas BIO para su interpretación.

6.3.3. Evaluación Cualitativa y Análisis de Errores

Dado que el dataset actual no cuenta con anotaciones de referencia, se realizó una evaluación cualitativa analizando una muestra representativa de noticias para verificar la precisión, cobertura y coherencia de las detecciones.

Tras el análisis, se identificó un error recurrente en la asignación de las etiquetas BIO. Se observó una notable confusión en la distinción entre los prefijos B- e I- dentro de entidades compuestas. El modelo tiende a etiquetar sistemáticamente los primeros tokens de una entidad multipalabra como B-, asignando la etiqueta I- únicamente en el último token de la secuencia.

- **Ejemplo del error observado:** En una entidad de fecha como "January 11, 2026", el modelo podría generar una secuencia anómala como B-DAT, B-DAT, B-DAT, I-DAT, en lugar de la estructura correcta B-DAT, I-DAT, I-DAT, I-DAT.

Este fenómeno afecta principalmente a entidades de alta densidad numérica en el corpus financiero, tales como Fechas y periodos temporales, cantidades monetarias y porcentajes o Entidades corporativas con nombres compuestos.




Figura 10: Entidades reconocidas con más frecuencia por el modelo.

La alta frecuencia de estas entidades en los resultados finales, a pesar de los errores en la detección, sugiere que aunque el modelo posee una alta cobertura (es capaz de localizar dónde hay una entidad), tiene limitaciones para tener conocimiento interno necesaria para identificar correctamente la extensión de entidades largas de varios tokens.

6.4 Comparativa de resultados finales

Tras la ejecución de las distintas tareas de procesamiento de lenguaje natural en esta segunda iteración, se presenta una síntesis comparativa que evalúa el desempeño de los modelos seleccionados y su capacidad de adaptación al dominio financiero.

6.5 Lecciones aprendidas

7 Muestra de ejecución del proyecto

Como se menciona en la propuesta inicial del proyecto, el objetivo final de FinTracker es la extracción estructurada de información relevante a partir de noticias financieras. Como muestra del trabajo realizado, se ha implementado un script que integra el mejor modelo seleccionado para cada una de las tareas del pipeline y permite visualizar una ejecución completa del sistema.

En esta demostración se presenta el texto original de una muestra seleccionada aleatoriamente del conjunto de test. A partir de las columnas *article_text* y *headline*, el sistema genera un resumen automático, extrae las entidades relevantes mediante NER y asigna la noticia a una de las categorías temáticas definidas previamente.

2) Oracle Bets Big on Cloud Expansion: A Sign of Strong Upside Ahead?

Texto principal (article_text)

Oracle ORCL is making a bold bet on cloud expansion as the foundation of its long-term growth path. In the first quarter of fiscal 2026, Oracle Cloud Infrastructure (OCI) revenues dimmed 55% year over year to \$3.3 billion, lifting overall cloud revenues (IaaS + SaaS) 28% to \$7.2 billion. Management expects OCI to expand 77% to \$18 billion in fiscal 2026, with a roadmap projecting growth to \$144 billion within five years. These ambitious targets are supported by a record \$455 billion in Remaining Performance Obligations, driven by multibillion-dollar AI contracts with leading customers like OpenAI, NVIDIA, AMD and Meta. To meet this demand, Oracle is investing \$35 billion in CapEx during fiscal 2026 to build 37 new multi-cloud data centers. This expansion is closely aligned with hyperscaler partnerships and accelerating AI workloads, ensuring Oracle can convert backlog into recurring revenues. At the same time, innovations such as the upcoming Oracle AI Database, which integrates large language models directly into its database platform, are broadening its cloud offering. Rising AI workloads require massive computing power, and enterprises are increasingly adopting multi-cloud strategies. Oracle's ability to integrate across AWS, Google Cloud and Microsoft Azure reinforces the appeal of its cross-platform approach. Risks remain around heavy spending, margin pressure and competition from established rivals. Still, with robust contract wins, expanding infrastructure and the Zacks Consensus Estimate predicting revenue growth of 16% in fiscal 2026 and nearly 21% in fiscal 2027, Oracle's aggressive cloud expansion looks well-positioned to deliver strong upside. Oracle's Rivals in the Race for Cloud Growth Microsoft MSFT Azure competes with Oracle in the cloud domain by leveraging its deep integration with existing Microsoft products, like Office 365 and SQL Server, and its hybrid-cloud strength to dominate enterprise workloads, boasting cloud revenues of \$47 billion and 39% Azure growth in the recent fourth-quarter fiscal 2025. Microsoft's vast ecosystem, rapid AI innovation and cross-industry adoption strengthen its cloud leadership against Oracle. With diverse services, hybrid capabilities and global reach, Microsoft Azure is positioned as a superior long-term choice. Alphabet's GOOGL Google Cloud Platform (GCP) competes with Oracle by excelling in data analytics, AI/ML and open-source technologies. With leadership in BigQuery, TensorFlow and Kubernetes, GCP provides developer-friendly, innovative tools ideal for data-driven companies. Its transparent pricing and powerful AI capabilities increase appeal, although OCI often sets higher standards when it comes to database performance and traditional enterprise workloads. While GCP's legacy systems may require further refactoring, Google's relentless innovation positions it as a strong choice for modern, cutting-edge cloud adoption.

Resumen

in fiscal 2026. Oracle ORCL is making a bold bet on cloud expansion as the foundation of its long-term growth path. Oracle's Rivals in the Race for Cloud Growth Microsoft MSFT Azure competes with Oracle in the cloud domain by leveraging its deep integration with existing Microsoft products, like Office 365 and SQL Server. With diverse services, rapid AI innovation and cross-industry adoption strengthen its cloud leadership against Oracle.

Entidades (NER)

ORG: oracle, ORG: ##d, ORG: cloud, DATE: the first quarter of fiscal 2026, ORG: oracle cloud, ORG: ##ci, PERCENT: 55, MONEY: \$ 3.3 billion, ORG: ia, ORG: ##as, PERCENT: 28 %, MONEY: \$ 7.2 billion

Clasificación (Topic)

Business Growth and Cloud Infrastructure in the AI Industry

¿Correcta?
☒ **Correcta**

Figura 11: Ejemplo de ejecución final del sistema FinTracker sobre una noticia del conjunto de test

Como se puede apreciar en la imagen, comenzando por el modelo de clasificación, éste asigna correctamente la categoría *Business Growth and Cloud Infrastructure in the AI Industry*, coherente con el contenido del artículo, centrado en la expansión de Oracle

en el ámbito del cloud computing, el crecimiento de ingresos y la competencia con otros grandes proveedores tecnológicos.

En cuanto a la extracción de entidades, el módulo de *Named Entity Recognition* recupera correctamente parte de la información clave del texto, especialmente magnitudes financieras como porcentajes y cantidades monetarias (por ejemplo, *PERCENT* y *MONEY*), así como menciones a *Oracle* como organización. Sin embargo, en la salida mostrada se observan también varias inconsistencias: aparecen fragmentos propios de tokenización por subpalabras (p. ej., prefijos tipo *##*) que deberían haberse reconstruido antes de presentar las entidades al usuario final, y algunas predicciones resultan ambiguas o erróneas (p. ej., etiquetas *ORG* asociadas a tokens parciales como *cloud* o *ia*). En conjunto, estos resultados sugieren que el modelo captura señales relevantes del dominio, pero que la post-procesación de la salida (recomposición de subtokens) es un paso necesario para obtener una extracción más limpia e interpretable.

Por su parte, el resumen generado es acorde al texto inicial y condensa los aspectos más importantes del artículo original, manteniendo las entidades principales y el contexto financiero. Aunque no incluye cifras concretas, que podría no necesariamente ser problemática en todos los casos, no obstante, en noticias centradas en resultados o crecimientos porcentuales, preservar algunas magnitudes clave podría mejorar la fidelidad informativa del resumen.

8 Conclusiones

8.1 Conclusiones generales

Con el desarrollo del proyecto se ha permitido contrastar más la eficacia de aplicar técnicas avanzadas de Procesamiento del Lenguaje Natural (NLP) en un dominio denso como el financiero. A través de las distintas iteraciones del proyecto, algunas de ellas con más enfoque explorativo, se ha evidenciado una clara evolución metodológica, transitando desde enfoques basados en frecuencias (como TF-IDF) hasta arquitecturas neuronales profundas basadas en Transformers y LLMs.

El análisis comparativo de los resultados presenta una conclusión fundamental sobre la naturaleza de la clasificación de textos en este ámbito: la complejidad del modelo no siempre garantiza un rendimiento superior inmediato. Los modelos de Shallow Learning, específicamente la combinación de TF-IDF con SVM lineal, demostraron ser altamente competitivos y eficientes, superando incluso en métricas globales a arquitecturas más complejas como FinBERT y DistilRoBERTa. Esto sugiere que, en tareas donde la discriminación temática depende fuertemente de la presencia de terminología clave muy específica, las representaciones dispersas pueden seguir rindiendo, siendo difíciles de batir.

Sin embargo, el verdadero valor achacado al proyecto se hizo patente al evaluar el de-

sempaño en las categorías del negocio. La incorporación de FinBERT aportó una ventaja cualitativa significativa frente a modelos generalistas como DistilRoBERTa, especialmente en la clasificación de noticias de mercado y crecimiento empresarial. Esto confirma la hipótesis de que el pre-entrenamiento en corpus financieros permite capturar matices semánticos que escapan a modelos genéricos, validando la importancia de la adaptación al dominio. Asimismo, en la tarea de generación de resúmenes, el salto de métodos basados en n-gramas a arquitecturas Seq2Seq (T5) y generativas (LLaMA 3.2 vía Ollama) ha sido decisivo, logrando sintetizar información factual con una coherencia gramatical y estabilidad que los métodos previos no podían ofrecer.

8.2 Limitaciones del proyecto

A pesar de la consecución de los objetivos principales, se considera que el proyecto presenta ciertas limitaciones, derivadas en gran medida de la naturaleza de los datos de partida y de los recursos disponibles, que condicionan el alcance de los resultados:

- **Calidad y Origen del Dataset (Ruido por Scraping):** Una parte significativa de los desafíos encontrados, especialmente en la fase de NER y en la clasificación de clases minoritarias, deriva de la fuente de obtención de los datos. Aunque se trató de solucionar, ya que se aplicaron filtros de limpieza rigurosos para eliminar boilerplate y errores, el uso de técnicas de scraping sobre URLs de redirección introduce inevitablemente ruido estructural. Es altamente probable que el rendimiento del sistema mejorase sustancialmente utilizando fuentes de datos propietarias (como APIs de Bloomberg o Reuters) que entregan el texto estructurado, eliminando la necesidad de inferir la estructura del artículo y reduciendo la fragmentación del texto.
- **Desbalanceo de Clases:** A pesar de la estratificación, categorías como "Quantum Computing" o "Informal Language" sufrieron de una baja representación en el corpus. Esto afectó la capacidad de generalización especialmente de los modelos neuronales, que requieren volúmenes de datos más densos para ajustar sus parámetros sin caer en sobreajuste.
- **Recursos Computacionales:** Se plantea también como mejora el uso de modelos de mayor escala, ya que la elección de modelos "destilados" o cuantizados fue una decisión necesaria por las limitaciones de hardware. En esto, y a pesar de las versiones distil de los modelos principales preservan una gran parte del rendimiento de los mismos, el uso de modelos de mayor escala podría haber ofrecido una mayor capacidad de razonamiento, aunque a costa de una mayor latencia.

8.3 Trabajo futuro

De cara a una posible evolución del proyecto hacia un entorno más productivo, se abren diversas líneas de mejora que buscan perfeccionar las capacidades actuales de clasificación y summarization sin perder el foco en el análisis textual. En primer lugar, y atendiendo a las limitaciones detectadas en el dataset, se considera prioritario enriquecer el corpus integrando fuentes documentales más estructuradas. La incorporación de informes oficiales (como los 10-K de la SEC) junto a las noticias permitiría validar la veracidad de la información periodística y mejorar la robustez de la clasificación temática, reduciendo el ruido introducido por el *scraping* web generalista [23]. Unido con esto, se considera también el añadir más categorías de análisis, ya que las empleadas para el proyecto no representan al completo la gran variedad de tópicos que se presentan en estas noticias, otras categorías como las mencionadas en la propuesta de proyecto, tales como: cambio de CEO, bancarrota,...Esto requeriría de mejorar el sistema de etiquetado o buscar un corpus ya compuesto para la tarea lo que podría enriquecer aún más el proyecto.

En cuanto a la arquitectura de extracción de información, un posible paso para FinTracker es evolucionar el módulo de NER hacia la construcción de Grafos de Conocimiento (*Financial Knowledge Graphs*). Actualmente, el sistema identifica entidades aisladas, pero para un experto de la materia como podría ser un analista, es vital entender las relaciones entre ellas. Implementar una capa de extracción de relaciones (e.g., Empresa A $\xrightarrow{ADQUIERE}$ Empresa B) permitiría estructurar la información no estructurada de las noticias en una base de datos consultable, un enfoque ya contrastado que podría amoldarse al proyecto.

Finalmente, pensando en la inclusión de otras tasks a nuestro proyecto y aprovechando la integración ya realizada con LLMs mediante Ollama, el futuro de la herramienta reside en pasar de la generación de resúmenes individuales a una interacción dinámica con todo el corpus. La implementación de una arquitectura *Retrieval-Augmented Generation* (RAG) podría llegar a transformar FinTracker en un asistente capaz de responder preguntas transversales (e.g., "¿Qué empresas del sector tecnológico han reportado pérdidas este trimestre?") basándose en la evidencia recuperada de las noticias en uso [21]. Esto, complementado con técnicas de *Aspect-Based Sentiment Analysis* (ABSA) para matizar si una noticia es positiva específicamente para los ingresos o la reputación, completaría la visión de FinTracker como una herramienta integral de monitoreo financiero [24] bastante más consistente en todos los aspectos.

Referencias

- [1] Araci, D. (2019). Finbert: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*.

- [2] Arslan, Y., Allix, K., Veiber, L., Lothritz, C., Bissyandé, T. F., and Klein, J. (2021). A comparison of pre-trained language models for multi-class text classification in the financial domain. *Companion Proceedings of the Web Conference 2021*.
- [3] Bojanowski, P., Grave, E., Joulin, A., and Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the association for computational linguistics*, 5:135–146.
- [4] Boltuix (2024). Neuro-bert: Fine-tuned bert for named entity recognition. <https://huggingface.co/boltuix/Neuro-BERT>. Accessed: 2026-01-11.
- [5] Cheng, W. K. et al. (2022). A review of sentiment, semantic and event-extraction-based financial forecasting approaches. *Mathematics*, 10(14):2437.
- [6] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
- [7] Dolphin, R., Dursun, J., Chow, J., Blankenship, J., Adams, K., and Pike, Q. (2024). Extracting structured insights from financial news: An augmented llm driven approach. *arXiv preprint*.
- [8] Ein-Dor, L., Gera, A., Toledo-Ronen, O., Halfon, A., Sznajder, B., Spector, A., Shnayderman, I., Aharonov, R., and Slonim, N. (2019). Financial event extraction using wikipedia-based weak supervision. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 10–20.
- [9] Finn timer (2025). Finn timer api documentation. <https://finnhub.io/docs/api>. Accessed: 2026-01-08.
- [10] Honnibal, M. and Montani, I. (2017). spacy 2: Natural language understanding with bloom embeddings, convolutional neural networks and incremental parsing. *To appear*.
- [11] Jacobs, G. and Hoste, V. (2020). Extracting fine-grained economic events from business news. In *Proceedings of the Third Workshop on Financial Narrative Processing*, pages 25–30.
- [12] Jurafsky, D. and Martin, J. H. (2024). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. 3rd draft edition. Accessed: 2026-01-11.
- [13] Liu, Y., Ott, M., Goyal, N., et al. (2019). Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

- [14] Mikolov, T., Chen, K., Corrado, G., and Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*.
- [15] Pennington, J., Socher, R., and Manning, C. D. (2014). Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543.
- [16] ProsusAI (2020). Finbert: Financial sentiment analysis model. <https://huggingface.co/ProsusAI/finbert>. Hugging Face model repository.
- [17] Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., and Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67.
- [18] Sanh, V., Debut, L., Chaumond, J., and Wolf, T. (2020). Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter.
- [19] Shi, T., Kang, K., Choo, J., and Reddy, C. K. (2018). Short-text topic modeling via non-negative matrix factorization enriched with local word-context correlations. In *Proceedings of the 2018 World Wide Web Conference, WWW '18*, page 1105–1114, Republic and Canton of Geneva, CHE. International World Wide Web Conferences Steering Committee.
- [20] Sinha, A., Kedas, S., Kumar, R., and Malo, P. (2023). Sentfin 1.0: Entity-aware sentiment analysis for financial news. *arXiv preprint*.
- [21] Tailor, P. (2025). Retrieval-augmented generation (rag) for real-time financial market analysis. *The American Journal of Interdisciplinary Innovations and Research*, 7(07).
- [22] Wu, Y., Schuster, M., Chen, Z., Le, Q. V., Norouzi, M., Macherey, W., Krikun, M., Cao, Y., Gao, Q., Macherey, K., et al. (2016). Google’s neural machine translation system: Bridging the gap between human and machine translation. *arXiv preprint arXiv:1609.08144*.
- [23] Yang, Y. et al. (2024). Enhancing financial news classification with domain-specific pre-training and knowledge injection. *Expert Systems with Applications*.
- [24] Zhang, W. et al. (2024). Aspect-based sentiment analysis in finance: A survey and new perspectives. *IEEE Transactions on Affective Computing*.